

Lösung zu Übungsblatt 2

Daten einlesen und bearbeiten mit dplyr

zu Vorlesung 2

Vorlage: Exercises/UE02_Aufgaben.R

Daten: Data/Input/Gebrauchtwagen.csv, 863 Fahrzeuge mit Typ, Alter (Monate), Fahr (Tsd. km), Hub (100 cm³), Wert (Euro)

Pakete: readr, dplyr

Aufgabe 1: Einlesen

Lesen Sie den Datensatz mit `read_delim()` ein. Die Datei nutzt das Semikolon als Trenner und das Komma als Dezimalzeichen. Zeigen Sie die ersten Zeilen und die Größe des Datensatzes an.

Kontrollwert: 863 Zeilen, 6 Spalten

Musterdeutung: `read_csv()` wäre hier falsch: Es trennt am Komma und zerlegt damit die Dezimalzahlen.

Aufgabe 2: Überblick

Welche Fahrzeugtypen gibt es, und wie viele sind es?

Kontrollwert: 9 Typen

Aufgabe 3: Filtern mit `filter()`

1. Alle Fahrzeuge mit einem Wert über 10.000 Euro.
2. Alle Fahrzeuge, deren Typ BMW oder Audi enthält.
3. Alle Fahrzeuge, die älter als 50 Monate und teurer als 15.000 Euro sind.

Tip: Schauen Sie zuerst mit `unique()` nach, wie die Typen genau heißen.

Kontrollwert: 297; 286; 11 Fahrzeuge

Musterdeutung: `filter(Typ == "BMW")` findet 0 Zeilen, und R meldet keinen Fehler, denn der Typ heißt „5er BMW“.

Aufgabe 4: Neue Variable mit `mutate()`

Bilden Sie `alter_jahr = Alter / 12`, auf zwei Stellen gerundet. Wie alt sind die Fahrzeuge im Mittel in Jahren?

Kontrollwert: 5,74

Aufgabe 5: Gruppieren mit `group_by()` und `summarize()`

Berechnen Sie mittleres Alter und mittleren Wert je Typ und sortieren Sie nach dem Alter.

Kontrollwert: jüngster Typ Opel Vectra (48,8 Monate), ältester Mazda 323 (92,1 Monate)

Musterdeutung: Der 5er BMW hat mit 19.091 Euro den höchsten mittleren Wert und gehört zugleich zu den jüngsten Typen.

R-Code der Lösung

```
# Übungsblatt 2: Daten einlesen und bearbeiten mit dplyr (zu Vorlesung 2)
# Lösung

# Einmalig installieren, falls noch nicht vorhanden: dazu das # vor install.packages entfernen
# install.packages("readr")
library(readr)
# install.packages("dplyr")
library(dplyr)

# Aufgabe 1: Einlesen
# Semikolon als Trenner, Komma als Dezimalzeichen: read_delim mit diesen Angaben
Gebrauchtwagen <- read_delim("Data/Input/Gebrauchtwagen.csv",
                             delim = ";",
                             locale = locale(decimal_mark = ","),
                             trim_ws = TRUE)

head(Gebrauchtwagen)
dim(Gebrauchtwagen)           # 863 Zeilen, 6 Spalten

# Aufgabe 2: Überblick
unique(Gebrauchtwagen$Typ)     # die genauen Namen der Typen
length(unique(Gebrauchtwagen$Typ)) # 9

# Aufgabe 3: Filtern
# 1. Wert über 10.000 Euro
teuer <- Gebrauchtwagen %>%
  filter(Wert > 10000)
nrow(teuer)                   # 297

# 2. Typ enthält BMW oder Audi. Die Namen lauten "5er BMW", "Audi A4" und "Audi A6";
#   filter(Typ == "BMW") fände 0 Zeilen.
bmw_audi <- Gebrauchtwagen %>%
  filter(Typ %in% c("5er BMW", "Audi A4", "Audi A6"))
nrow(bmw_audi)                # 286
# gleichwertig: filter(grepl("BMW/Audi", Typ))

# 3. Alter als 50 Monate und teurer als 15.000 Euro
alt_teuer <- Gebrauchtwagen %>%
  filter(Alter > 50 & Wert > 15000)
nrow(alt_teuer)               # 11

# Aufgabe 4: Neue Variable
Gebrauchtwagen <- Gebrauchtwagen %>%
  mutate(alter_jahr = round(Alter / 12, digits = 2))
mean(Gebrauchtwagen$alter_jahr) # 5.74 Jahre

# Aufgabe 5: Gruppieren und Zusammenfassen
Gebrauchtwagen %>%
  group_by(Typ) %>%
  summarize(Mittelwert_Alter = mean(Alter),
            Mittelwert_Wert = mean(Wert)) %>%
  arrange(Mittelwert_Alter)
# Jüngster Typ: Opel Vectra (48,8 Monate), ältester: Mazda 323 (92,1 Monate).
# Höchster mittlerer Wert: 5er BMW (19.091 Euro).
```