

Lösung zu Übungsblatt 3

Deskriptive Statistik

zu Vorlesung 3

Vorlage: Exercises/UE03_Aufgaben.R

Daten: Data/Input/Gebrauchtwagen.csv, Variable Fahr (Fahrleistung in Tausend Kilometern)

Die Vorlesung hat das Alter untersucht, hier übertragen Sie dieselben Schritte auf die Fahrleistung.

Faustregel für die Stärke eines Zusammenhangs (Betrag des Koeffizienten, angelehnt an Fahrmeir et al.): unter 0,5 schwach, 0,5 bis unter 0,8 mittel, ab 0,8 stark.

Aufgabe 1: Lage

Berechnen Sie Mittelwert und Median der Fahrleistung.

Kontrollwert: 83,19; 81

Aufgabe 2: Streuung

Berechnen Sie Standardabweichung, Varianz und Spannweite.

Kontrollwert: 47,35; 2.241,72; 270,5

Aufgabe 3: Quantile

Berechnen Sie die Quartile, den Interquartilsabstand und das 90%-Quantil.

Kontrollwert: 46,8; 81; 114,85; 68,05; 149,8

Musterdeutung: Bei jedem zehnten Fahrzeug liegt die Fahrleistung über 149.800 km.

Aufgabe 4: Grafiken

Zeichnen Sie ein Histogramm mit senkrechten Linien für Median und Mittelwert und einer Legende. Zeichnen Sie einen Boxplot der Fahrleistung je Typ. Welcher Typ hat den höchsten, welcher den niedrigsten Median?

Kontrollwert: VW Passat (112,5); Opel Vectra (57)

Aufgabe 5: Zusammenhang mit dem Wert

Zeichnen Sie ein Streudiagramm von Fahrleistung und Wert. Berechnen Sie die Korrelation nach Pearson und nach Spearman und stufen Sie sie nach der Faustregel ein.

Kontrollwert: -0,56; -0,61

Musterdeutung: Beide Werte liegen zwischen 0,5 und 0,8: eine mittlere, gegenläufige Korrelation.

Aufgabe 6: Deutung

Beschreiben Sie in zwei Sätzen die Form der Verteilung und den Zusammenhang mit dem Wert.

Musterdeutung: Der Mittelwert (83,19) liegt etwas über dem Median (81): Die Verteilung ist leicht rechtsschief, einige Fahrzeuge haben sehr viele Kilometer. Je höher die Fahrleistung, desto geringer ist im Mittel der Wert.

R-Code der Lösung

```
# Übungsblatt 3: Deskriptive Statistik (zu Vorlesung 3)
# Lösung. Variable: Fahrleistung Fahr in Tausend Kilometern

# Einmalig installieren, falls noch nicht vorhanden: dazu das # vor install.packages entfernen
# install.packages("readr")
library(readr)
Gebrauchtwagen <- read_delim("Data/Input/Gebrauchtwagen.csv",
                             delim = ";",
                             locale = locale(decimal_mark = ","),
                             trim_ws = TRUE)

fahr <- Gebrauchtwagen$Fahr

# Aufgabe 1: Lage
mean(fahr)           # 83.19
median(fahr)         # 81

# Aufgabe 2: Streuung
sd(fahr)             # 47.35
var(fahr)            # 2241.72
range(fahr)          # 0.5 bis 271
diff(range(fahr))    # Spannweite 270.5

# Aufgabe 3: Quantile
quantile(fahr)        # Quartile 46.8, 81 und 114.85
IQR(fahr)             # 68.05
quantile(fahr, probs = 0.9) # 149.8

# Aufgabe 4: Grafiken
hist(fahr, main = "Fahrleistung der Fahrzeuge", xlab = "Fahrleistung (Tsd. km)")
abline(v = median(fahr), col = "red", lwd = 2)
abline(v = mean(fahr), col = "blue", lty = 2, lwd = 2)
legend("topright", legend = c("Median", "Mittelwert"), col = c("red", "blue"),
       lty = c(1, 2), lwd = 2)

boxplot(Fahr ~ Typ, data = Gebrauchtwagen, las = 2, xlab = "",
        ylab = "Fahrleistung (Tsd. km)", main = "Fahrleistung nach Typ")
sort(tapply(fahr, Gebrauchtwagen$Typ, median))
# höchster Median: VW Passat (112,5), niedrigster: Opel Vectra (57)

# Aufgabe 5: Zusammenhang mit dem Wert
plot(fahr, Gebrauchtwagen$Wert, xlab = "Fahrleistung (Tsd. km)", ylab = "Wert (Euro)",
     main = "Fahrleistung und Wert")
cor(fahr, Gebrauchtwagen$Wert)           # -0.56
cor(fahr, Gebrauchtwagen$Wert, method = "spearman") # -0.61
# Nach der Faustregel aus VL3 eine mittlere Korrelation (0,5 bis unter 0,8).

# Aufgabe 6: Deutung
# Der Mittelwert (83,19) liegt etwas über dem Median (81): Die Verteilung ist leicht
# rechtsschief, einige Fahrzeuge haben sehr viele Kilometer. Je höher die Fahrleistung,
# desto geringer ist im Mittel der Wert; der Zusammenhang ist gegenläufig und mittelstark.
```